

Prova 1

Vitor Hugo de Oliveira Mello


Exercício 1.

Enunciado

Considere as curvas na imagem abaixo:

1. Qual das curvas é mais provável de ser o erro de treinamento e qual é mais provável de ser o erro de validação?
Indique no gráfico
2. Em quais regiões do gráfico o viés e a variância são baixos ou altos? Indique claramente no gráfico com quatro rótulos: Baixa Variância, Alta Variância, Baixo Viés, Alto Viés

1. Resolução




Exercício 2

Enunciado

O gráfico abaixo mostra o risco em um conjunto de validação em função de um hiperparâmetro, cujo valor aumenta ao longo do eixo x. Cada curva representa um modelo distinto:

- Uma árvore de decisão, cujo hiperparâmetro controla a força da poda.
- Uma floresta aleatória, cujo hiperparâmetro é o número de árvores.

Identifique qual curva corresponde a qual modelo e justifique sua resposta.



2. Resolução

Justificativa do Pruning

O método de pruning em árvores de regressão busca equilibrar a precisão do modelo e sua simplicidade, minimizando a seguinte função de erro:

$$\left(\sum_{m=1}^{|T|} \sum_{i: x_i \in R} (y_i - \hat{y}_R)^2 \right) + \alpha |T|$$

Sendo

- $|T|$ o número de nós terminais
- R a região associada ao m-ésimo nó terminal
- $\hat{y}$ é a média dos target em R
- α parâmetro que penaliza árvores mais complexas

Ou seja, somamos o erro quadrático de cada região e adicionamos uma penalização proporcional ao número de nós terminais

Dessa forma, α é proporcional ao viés e inversamente proporcional à variância

Justificativa do Número de Árvores

Uma maneira natural de reduzir a variância é gerar muitos subconjuntos de treinamento. Notar que, a média de várias observações reduz a variância. Exemplo, considere um conjunto de n observações independentes $Z_1, \dots, Z_n$, cada uma com variância σ^2 , a variância da média $\bar{Z}$ das observações é dada por σ^2/n .

Floresta Aleatória utiliza-se de Bootstrap aggregation (bagging) e bagging reduz a variância sem aumentar significativamente o viés

Exercício 3

Enunciado

Um conjunto de dados é gerado pelo seguinte processo

$$Y = w_0 + w_1 X + w_2 X^2 + w_3 X^3 + w_4 X^4 + \epsilon$$

em que X é uma variável aleatória real e ϵ é uma variável de ruído Gaussiano

Considere dois modelos candidatos para ajustar os dados:

1. $Y = w_0 + w_1 X + \epsilon$
2. $Y = w_0 + w_1 X + w_2 X^2 + \dots + w_9 X^9$

Responda às seguintes perguntas, justificando suas respostas:

a) Quando comparamos o Modelo 1 com o Modelo 2, utilizando uma amostra de treinamento de tamanho n , qual dos modelos apresenta maior viés? Explique o motivo

b) Quando comparamos o Modelo 1 com o Modelo 2, utilizando uma amostra de treinamento de tamanho n , qual dos modelos apresenta maior variância? Explique o motivo

c) Suponha que temos apenas 10 exemplos de treinamento. Qual dos dois modelos é mais propenso a ter uma performance ruim? Justifique sua resposta

3. Resolução

Quanto maior o número de features, mais complexo é a regressão linear. Dessa forma o viés diminui com mais features e a variância aumenta

a) Logo o viés do modelo 1 é maior que do modelo 2

b) Portanto a variância do modelo 1 é menor que do modelo 2

c) Para regressão linear temos que o erro de treino e teste são dados pelas seguintes fórmulas

$$R(\beta) = \sigma + \frac{\sigma p}{n} \quad [\text{teste}]$$

$$R(\beta) = \sigma - \frac{\sigma p}{n} \quad [\text{treino}]$$

$$p_2 > p_1$$

$$p_2/n > p_1/n$$

$$1 + p_2/n > 1 + p_1/n$$

$$\sigma(1 + p_2/n) > \sigma(1 + p_1/n)$$

$$R(\beta_2) > R(\beta_1)$$

Ou seja, o modelo 2 tem uma performance pior que o modelo 1, e como p está próximo de n o erro de treino vai ser mínimo e de teste vai ser máximo porque $p/n \rightarrow 1$

Exercício 4

Enunciado

Considere o problema clássico de mínimos quadrados, no qual temos uma matriz de dados $X \in \mathbb{R}^{n \times p}$ com colunas linearmente independentes e um vetor de respostas $Y \in \mathbb{R}^n$. O vetor de coeficientes $\hat{\beta}$ é obtido como a solução do problema de otimização:

$$\hat{\beta} = \arg \min_{\beta \in \mathbb{R}^p} \|Y - X\beta\|^2$$

O vetor de predições associadas ao modelo ajustado é dado por $\hat{Y} = X\hat{\beta}$

1. Mostre que $\hat{Y} = P\beta$, onde $X(X^T X)^{-1} X^T$. Verifique que $P^2 = P$ e $P^T = P$, ou seja, que P é idempotente e simétrica

2. Seja $r = Y - \hat{Y}$ o vetor de resíduos. Argumente geometricamente que r é ortogonal a $\hat{Y}$ e, em seguida, apresente uma prova formal dessa ortogonalidade

3.1 Resolução

β é encontrado minimizando o erro quadrático

$$\hat{\beta} = \arg \min_{\beta \in \mathbb{R}^p} \|Y - X\beta\|^2$$

Dado que estamos trabalhando no $\mathbb{R}^n$ calcular a derivada parcial da função de perda em relação a cada β_j e igualar a zero:

$$\frac{\partial}{\partial \beta} \|Y - X\beta\|^2 = 0$$

Sabemos que:

$$\begin{aligned}
\|Y - X\beta\|^2 &= (Y - X\beta)^T (Y - X\beta) = (Y^T - \beta^T X^T)(Y - X\beta) \\
&= Y^T Y - \underbrace{\beta^T X^T Y - Y^T X\beta}_{(\text{escalar})^T = \text{escalar}} + \beta^T X^T X\beta \\
&= Y^T Y - 2\beta^T X^T Y + \beta^T X^T X\beta
\end{aligned}$$

Derivadas parciais em relação a β :

$$\begin{aligned}
\frac{\partial}{\partial \beta} \|Y - X\beta\|^2 &= \frac{\partial}{\partial \beta} (Y^T Y - 2\beta^T X^T Y + \beta^T X^T X\beta) \\
&= -2X^T Y + \frac{\partial}{\partial \beta} (\beta^T X^T X\beta) \\
\frac{\partial}{\partial \beta} (\beta^T X^T X\beta) &= \frac{\partial}{\partial \beta} (\beta^T Q\beta), \text{ onde } Q = X^T X \text{ é simétrica} \\
&= \frac{\partial}{\partial \beta} \left(\sum_{i=1}^k \sum_{j=1}^k \beta_i q_{ij} \beta_j \right)
\end{aligned}$$

Considerando um elemento qualquer m, podemos dividir essa soma em 4:

$$1. i = j = m$$

$$\frac{\partial}{\partial \beta_m} (\beta_m q_{mm} \beta_m) = 2q_{mm} \beta_m$$

$$2. i = m \text{ e } j \neq m$$

$$\frac{\partial}{\partial \beta_m} \left(\sum_{j \neq m} \beta_m q_{mj} \beta_j \right) = \sum_{j \neq m} q_{mj} \beta_j$$

$$3. i \neq m \text{ e } j = m$$

$$\frac{\partial}{\partial \beta_m} \left(\sum_{i \neq m} \beta_i q_{im} \beta_m \right) = \sum_{i \neq m} \beta_i q_{im}$$

$$4. i \neq m \text{ e } j \neq m$$

$$\frac{\partial}{\partial \beta_m} \left(\sum_{i \neq m} \sum_{j \neq m} \beta_i q_{ij} \beta_j \right) = 0$$

Notar que a matriz Q é simétrica, logo $q_{mi} = q_{im}$. Somando as partes temos:

$$\begin{aligned}
\frac{\partial}{\partial \beta_m} (\beta^T Q\beta) &= 2q_{mm} \beta_m + \sum_{j \neq m} q_{mj} \beta_j + \sum_{i \neq m} \beta_i q_{im} + 0 \\
&= 2q_{mm} \beta_m + 2 \sum_{j \neq m} q_{mj} \beta_j \\
&= 2 \sum_{j=1}^k q_{mj} \beta_j
\end{aligned}$$

Logo:

$$\begin{aligned}
\frac{\partial}{\partial \beta} \|Y - X\beta\|^2 &= -2X^T Y + 2X^T X\beta = 0 \\
X^T Y &= X^T X\beta
\end{aligned}$$

E, como $X^T X$ é invertível (colunas linearmente independentes)

$$\hat{\beta} = (X^T X)^{-1} X^T Y$$

Portando a prediction $\hat{Y}$ é definida como:

$$\hat{Y} = X\hat{\beta} = X(X^T X)^{-1} X^T Y$$

Isolando $X(X^T X)^{-1} X^T$, temos:

$$P = X(X^T X)^{-1} X^T$$

$$\hat{Y} = PY$$

Verificação de que (P) é idempotente e simétrica:

Simetria:

$$P^T = (X(X^T X)^{-1} X^T)^T = X(X^T X)^{-1} X^T = P$$

Idempotência:

$$P^2 = PP = (X(X^T X)^{-1} X^T)(X(X^T X)^{-1} X^T)$$

Sabemos que:

$$X^T X(X^T X)^{-1} = I_p$$

Logo:

$$P^2 = X(X^T X)^{-1} I_p X^T = X(X^T X)^{-1} X^T = P$$

3.2 Resolução

Geometricamente, o vetor de resíduos $r = Y - \hat{Y}$ é ortogonal a $\hat{Y}$ porque representa a distância vertical entre cada ponto observado Y e o ponto predito pela regressão $\hat{Y}$. A distância mínima entre Y e qualquer ponto no espaço da regressão é a perpendicular à reta ou superfície que define o espaço da regressão. Portanto, o vetor r é ortogonal a $\hat{Y}$.

Prova formal:

Queremos mostrar que:

$$\langle r, \hat{Y} \rangle = r^T \hat{Y} = 0$$

Como:

$$r = Y - \hat{Y} = Y(1 - P)$$

então:

$$r^T \hat{Y} = (Y - PY)^T PY = (Y^T - Y^T P^T) PY = Y^T PY - Y^T P^T PY$$

Como P é simétrica e idempotente $P^T = P$ e $P^2 = P$, podemos escrever:

$$\langle r, \hat{Y} \rangle = r^T \hat{Y} = Y^T PY - Y^T P P Y = Y^T PY - Y^T P Y = 0$$

Assim, os resíduos são ortogonais a $\hat{Y}$.

Exercício 5

Exercício 5 (1.5 pts) Um modelo de classificação binária foi treinado para prever se um paciente possui uma determinada doença ($Y = 1$) ou não ($Y = 0$). O modelo estima uma probabilidade para cada paciente, e a decisão final é feita comparando essa probabilidade com um limiar de 0.5. A matriz de confusão obtida após aplicar o modelo é apresentada abaixo:

	$Y = 1$	$Y = 0$
$\hat{Y} = 1$	90	360
$\hat{Y} = 0$	10	540

- Com base na matriz acima, calcule a acurácia, a precisão e o recall do modelo (você pode deixar em forma de fração).
- Analise o cenário apresentado e discuta o desempenho do modelo com base nas métricas calculadas. Comente sobre possíveis limitações do classificador e sugira estratégias que poderiam ser adotadas para melhorar seus resultados.

5.1 Resolução

- Acurácia = $P(g(x) \neq y) = \frac{90+540}{90+10+360+540} = 0.63$
- Precisão = $P(Y = 1|g(x) = 1) = \frac{90}{90+360} = 0.2$
- Recall = $P(g(x) = 1|Y = 1) = \frac{90}{90+10} = 0.9$

5.2 Resolução

O modelo tem uma baixa precisão, principalmente porque o dataset está desbalanceado. Para melhorar o modelo nessa métrica podemos (1) mudar o limiar ou (2) podemos aumentar o número de $Y=1$, atualmente temos só 10% da base

Exercício 6

Enunciado

Exercício 6 (1.5 pts) Considere o seguinte procedimento aplicado sobre um conjunto de dados com n observações:

-
- 1: **for** $b = 1$ até B **do**
 - 2: Sorteie, com reposição, n pares (X_i, Y_i) do conjunto original para formar um conjunto de treino
 - 3: Ajuste um modelo $\hat{g}_b$ usando esse conjunto de treino
 - 4: **end for**
 - 5: Retorne a função final: $\hat{g}_{\text{final}}(x) = \frac{1}{B} \sum_{b=1}^B \hat{g}_b(x)$
-

- a) Que tipo de estratégia de modelagem está sendo utilizada neste procedimento? Justifique sua resposta com base nas etapas apresentadas.
- b) Suponha agora que, além de aplicar o procedimento acima para construir os modelos, você também decide construir o conjunto de teste sorteando n pares (X_i, Y_i) com reposição a partir do mesmo conjunto original. Essa forma de avaliação é adequada? Justifique sua resposta.
- c) Suponha que o modelo $\hat{g}_b$ utilizado seja o algoritmo k -NN. Como a escolha de k influencia o viés e a variância do modelo final $\hat{g}_{\text{final}}$? Além disso, discuta o que acontece com o desempenho do procedimento ao aumentar ou diminuir o valor de B .

6.1 Resolução

Este procedimento descreve a técnica de bagging (bootstrap aggregating). A justificativa baseia-se em:

1. Amostragem com reposição (bootstrap)
2. Ajuste de múltiplos modelos independentes
3. Agregação por média

6.2 Resolução

Não — esse esquema de avaliação não é adequado, porque o conjunto de teste deixa de ser independente dos treinos

6.3 Resolução

- Valor de K pequeno: $\uparrow$ Variância $\downarrow$ Vies, uma vez que vamos pegar poucos vizinhos. No limite pegamos só um ponto
- Valor de K grande: $\downarrow$ Variância $\uparrow$ Vies, uma vez que pegamos muitos vizinhos. No limite o modelo é a média de todos os pontos

Essa agregação (bagging) reduz a variância do estimador sem aumentar seu viés de forma significativa. Ou seja, quanto maior o B mais vai reduzir a variância

Exercício 7

Enunciado

Considere um problema de classificação binária em que a variável resposta $Y \in \{0, 1\}$, e a probabilidade condicional verdadeira é dada por $\eta(x) = P(Y = 1|x)$

1. Defina o classificador que maximiza a acurácia esperada dado $\eta(x)$.
2. Um estatístico estimou o classificador do item (a) em uma base com classes desbalanceadas, obtendo $\hat{\eta}(x)$. O modelo apresentou desempenho insatisfatório em termos de precisão e recall. Após ajustar o limiar de decisão para um valor diferente de 0.5, a performance melhorou. O estatístico ficou confuso, já que pelo item (a), essa escolha de classificador é que minimiza o erro. Esse comportamento contradiz a teoria? Justifique.

7.1 Resolução

Queremos minimizar $E[L(g(x), y)]$

$$E[L(g(x), y)] = E[\mathbb{I}\{g(x) \neq y\}] = E[E[\mathbb{I}\{g(x) \neq y\} | X = x]]$$

$$g^* = \arg \min_g E[E[\mathbb{I}\{g(x) \neq y\} | X = x]]$$

Analizando $E[\mathbb{I}\{g(x) \neq y\} | X = x]$

$$\begin{aligned} E[\mathbb{I}\{g(x) \neq y\} | X = x] &= P(g(x) \neq y | X = x) \\ &= P(Y = 1 | X = x) \mathbb{I}[g(x) = 0] + P(Y = 0 | X = x) \mathbb{I}[g(x) = 1] \\ &= \eta(x) \mathbb{I}[g(x) = 0] + (1 - \eta(x)) \mathbb{I}[g(x) = 1] \end{aligned}$$

- Se $\eta(x) \geq 0.5$, então $\eta(x) > 1 - \eta(x)$, escolhemos $g(x)=1$
- Se $\eta(x) < 0.5$, então $\eta(x) < 1 - \eta(x)$, escolhemos $g(x)=0$

7.2 Resolução

Não porque estamos minimizando a acurácia, ou seja, estamos minimizando $E[\mathbb{I}\{g(x) \neq y\}]$

Exercício 8

Enunciado

Considere um problema de predição onde se deseja estimar a perda de generalização de um preditor fixo g . Seja $L(g(X), Y) \in [0, 1]$ uma função de perda, e suponha que temos uma nova amostra i.i.d. de tamanho n , $(X_1, Y_1), \dots, (X_n, Y_n)$, gerada da mesma distribuição conjunta de (X, Y) . A perda empírica sobre essa nova amostra é definida por:

$$\hat{L}(g) = \frac{1}{n} \sum_{i=1}^n L(g(X_i), Y_i)$$

e a perda verdadeira é dada por:

$$L(g) = \mathbb{E}_{(X,Y)}[L(g(X), Y)]$$

1. Use a desigualdade de Markov para obter um limite superior para a probabilidade de que $\hat{L}(g) \geq \epsilon$, assumindo que $E[\hat{L}(g)] = \mu$ é conhecido.
2. Mostre que a variância de $\hat{L}(g)$ é no máximo $1/(4n)$, e use a desigualdade de Chebyshev para obter um limite superior para:

$$P(|\hat{L}(g) - L(g)| \geq \epsilon)$$

3. Interprete o resultado do item (b): como o tamanho da amostra afeta a confiança na estimativa do erro de generalização?

8.1 Resolução

A desigualdade de Markov é dada por

$$P(X \geq a) \leq \frac{\mathbb{E}[X]}{a}$$

Sendo $X = \hat{L}$ e $a = \epsilon$, temos

$$P(\hat{L} \geq \epsilon) \leq \frac{\mathbb{E}[\hat{L}]}{\epsilon} = \frac{\mu}{\epsilon}$$

8.2 Resolução

$$\hat{L}(g) = \frac{1}{n} \sum_{i=1}^n L(g(x_i), y_i) \Rightarrow \mathbb{V}\text{ar}(\hat{L}) = \mathbb{V}\text{ar}\left(\frac{1}{n} \sum_{i=1}^n L(g(x_i), y_i)\right) = \frac{n}{n^2} \mathbb{V}\text{ar}(L(g(x_i), y_i)) = \frac{\mathbb{V}\text{ar}(L(g(x_i), y_i))}{n}$$

Sendo $L = L(g(x_i), y_i)$ e $L \in [0, 1]$, temos:

$$\begin{aligned} \text{Var}(L) &= E(L^2) - E^2(L), \quad E[Z^2] \leq E[Z] \\ \text{Var}(L) &\leq E(L) - E^2(L) = E(L)(1 - E(L)), \quad \text{sendo } p = E(L) \\ \text{Var}(L) &\leq p(1 - p) \quad \text{maximo quando } p = 1/2 \\ \text{Var}(L) &\leq 1/4 \end{aligned}$$

Portanto

$$\mathbb{V}\text{ar}(\hat{L}) \leq \frac{1}{4n}$$

Desigualdade de Chebyshev

$$P(|X - \mu| \geq \epsilon) \leq \frac{\sigma^2}{\epsilon^2}$$

Sendo $X = \hat{L}(g)$, temos $\mu = \mathbb{E}[\hat{L}] = L(g)$, substituindo na desigualdade ficamos com

$$P\left(|\hat{L}(g) - L(g)| \geq \epsilon\right) \leq \frac{1}{\epsilon^2} \frac{1}{4n}$$

8.3 Resolução

- Quanto menor $|\hat{L}(g) - L(g)|$ maior a confiança
- Logo queremos que $P\left(|\hat{L}(g) - L(g)| \geq \epsilon\right)$ seja a menor possível
- Portanto quanto maior n menor é $P\left(|\hat{L}(g) - L(g)| \geq \epsilon\right)$, dessa forma maior a confiança